預訓練模型

背景知識

Transformer:

由<<Attention Is All You Need>>[1]這篇論文所提出，其使用 Encoder-decoder 結構:encoder 將輸入(input)的序列$(x_1, \dots, x_n)$標註為連續的序列$\boldsymbol{z} = z_1, \dots, z_n$，而 decoder 根據序列$\boldsymbol{z}$生成輸出(output)序列$(y_1, \dots, y_n)$，而模型的這些步驟皆擁有自回歸(auto-regressive)的特性，也就是將前個時間步t的輸出y_t作為下個時間步$t+1$的輸入。

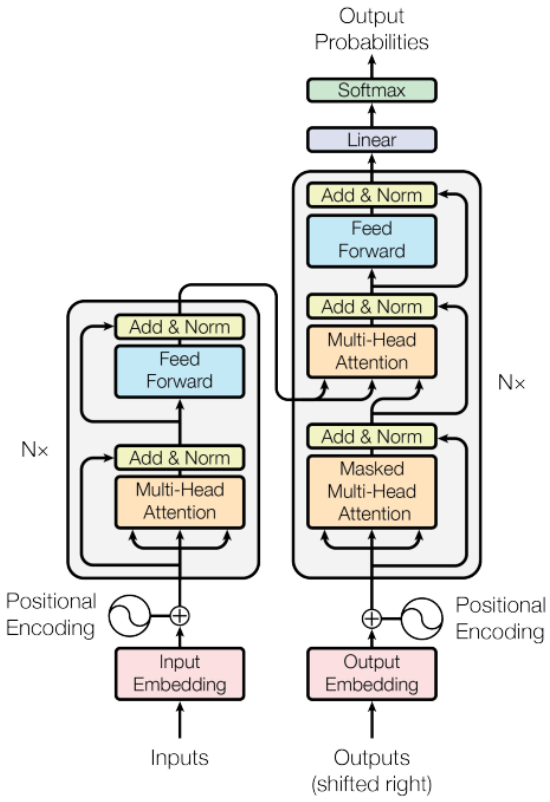

The Transformer – 模型結構

[1] https://arxiv.org/abs/1706.03762

Encoder:

在<<Attention Is All You Need>>這篇論文中，Transformer 的 Encoder 使用$N = 6$層相同的編碼器(identical layers)組成，每層都有兩個子層(sub-layers)組成。第一子層是一個 Multi-Head Self-Attention，第二子層是一個簡單的 Position-wise Fully Connected Feed-forward Network，子層和子層間使用 Residual Connection 後接著 Layer Normalization，意味著每個子層的輸出為$LayerNorm\big(x + Sublayer(x)\big)$。為了使 Residual Connection 可行，所有層的輸出維度必須相同，因此固定$d_{model} = 512$。

Decoder:

在<<Attention Is All You Need>>這篇論文中，Transformer 的 Decoder 同樣使用$N = 6$層相同的編碼器組成，每層除了原本的兩個子層，更加入了第三個子層 Multi-performs Attention，加入這層的原因是為了防止 Decoder 的子層提前注意到了還未解讀的內容，子層和子層間同樣使用 Residual Connection 後接著 Layer Normalization。

Attention:

這是一種函數，它會根據一個 query vector 和一組 key-value pairs，產生一個 output vector。Output vector 是通過 values 的加權總合得到，而每個值的加權由 compatibility function 得到。

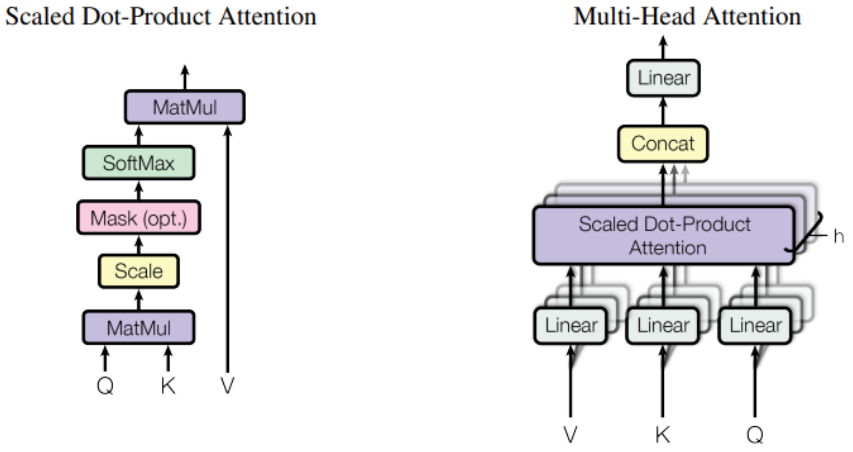

Scaled Dot-Product Attention:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)\text{V}$$

d_k是 Key 向量的維度，$\sqrt{d_k}$是以 query 和所有 keys 做 dot-product 得到的結果，矩陣 Q 是矩陣包裝的注意力函數，K 為 keys vector，V 為 values vector。

Multi-Head Attention:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

$$where\ head_i = Attention\left(QW_i^Q, KW_i^K, VW_i^V\right)$$

h是計算注意力的次數，意味著它有h個 head，使這個模型可以關注到不同表現的資訊。

每個 head 都有自己的線性投影矩陣，將原始d_{model}維的 query、key 和 value 映射到更小的維度(d_k, d_k, d_v)，則以上過程可以用以下矩陣表示:

$$W_i^Q \in R^{d_{model} \times d_k}, W_i^K \in R^{d_{model} \times d_k}, W_i^V \in R^{d_{model} \times d_v}, and\ W^O \in R^{hd_v \times d_{model}}$$

Position-wise Feed-Forward Networks with ReLU:

$$FFN(x) = \max(0, \mathrm{x}\mathrm{W}_1 + \mathrm{b}_1)\mathrm{W}_2 + \mathrm{b}_2$$

FNN 的輸入和輸出維度$d_{model} = 512$，而內部隱藏層的維度$d_{ff} = 2048$。

Embeddings and Softmax:

Embedding 是將 Input tokens 和 Output tokens 轉換成向量的技術，而 Softmax 則是將 Output vector 轉換成機率的函數。Transformer 採用了一樣的參數矩陣在 Embedding Matrix 和 Pre-Softmax Linear Transformation 中，並將 Embedding 的權重乘上$\sqrt{d_{model}}$。

Positional Encoding

在<<Attention Is All You Need>>這篇論文中，因為 Transformer 模型沒有 RNN 或 CNN 結構，所以需要 PE 來讓模型理解序列的順序。於是 Transformer 模型在 Input embeddings 的最後加入了 Positional encodings，來讓模型知道位置的關係。在 Transformer 模型中使用 sine 和 cosine 函數達成這個目的:

$$PE_{pos,2i} = sin\left(pos/10000^{2i/d_{model}}\right)$$

$$PE_{pos,2i+1} = cos\left(pos/10000^{2i/d_{model}}\right)$$

pos 是位置，i 是維度。

BERT

引用資料:

https://haren.medium.com/paper-notes-bert-bert-%E6%9E%B6%E6%A7%8B%E7%90%86%E8%A7%A3-31c014d7dd63

https://arxiv.org/pdf/1810.04805

全名:Bidirectional Encoder Representations from Transformers

使用 Masked LM(MLM)和 Next Sentence Prediction(NSP)捕捉 token-level 和 sentence-level 的特徵。也就是透過遮住某個詞語來讓模型預測被遮住的詞語。

GPT

引用資料:

https://reurl.cc/mxGN0A

全名:Generative Pre-trained Transformer

GPT 僅採用 Transformer decoder 的部分，透過前面的文字序列來預測下一個單詞，或透過周圍的語境來推斷缺失單詞的意思。

PaLM

引用資料:

https://arxiv.org/pdf/2204.02311

全名:Pathways Language Model

PaLM 採用完整的 Transformer 架構，並使用 Pathways 架構訓練，使其可以同時學習多種不同的任務。

LLaMA

引用資料:

https://ithelp.ithome.com.tw/m/articles/10366983

全名:Large Language Model Meta AI

LLaMA 僅採用 Transformer decoder 的部分，相比於 Transformer 的 LayerNorm，它使用 RMSNorm，且使用更加平滑的 SwiGLU 函數作為激活函數。

訓練資料集

AutoMathText

引用資料: https://arxiv.org/pdf/2402.07625

此資料集是一個經過精心整理的資料集，包含約 200GB 的數學文字。這個資料集來自不同平台，包含各種網站、arXiv 和 GitHub(OpenWebMath、RedPajama、Algebraic Stack)等。這個豐富的資料庫是由最先進的開放原始碼語言模型 Qwen-72B 所自主選擇 (標籤)。資料集中的每篇內容都會在 [0, 1] 的範圍內分配一個分數 lm_q1q2_score，以反映其在數學智慧方面的相關性、品質與教育價值。